

Objetivo obligatorio (5.5 puntos)

- **Segmentación basada en características de color (3.5 puntos):**

Espacio de color y análisis visual

Cambiamos la imagen original (modificada para que su tamaño sea de 500x496) al plano de color Lab para más tarde extraer sus componentes a y b para representar tanto estas en un mesh, como los píxeles de I en el espacio de color ab en un scatter plot.

Selección de patches

Para el patch del fondo hemos empleado 3 puntos distintos porque con solo 1 aparecían anomalías más adelante en el filtro posterior y la segmentación de la imagen. También hemos definido uno para cada pelota, compartiendo ambas pelotas verdes el mismo.

Preparación de conjuntos de observaciones balanceados

Calculamos el número de píxeles de cada patch viendo su tamaño con size para luego ver el número mínimo de píxeles de los 4 patches para balancear. Como vamos a generar índices aleatorios, fijamos la semilla con rng(123) para que cada vez que se ejecute el código no se utilicen valores muy distintos.

Construcción de conjuntos de entrenamiento y validación

Creamos un vector para estas etiquetas ya balanceadas. Creamos los conjuntos X_val y T_val, así como X_train y T_train y visualizamos ambos conjuntos (entrenamiento y validación) en otro scatter plot.

Selección del hiperparámetro k

Damos varios valores elegidos deliberadamente para ver cual de ellos da mejores resultados, en este caso [1, 3, 5, 7, 9, 11, 15, 21, 31, 51]. Empleamos el modelo k-NN y evaluamos el rendimiento de cada valor, para llegar a la conclusión final de que 21 es el valor óptimo para k. Este siempre será el mismo debido a la limitación en la aleatoriedad antes aplicada. Tras determinar el k elegido, entrenamos el modelo final con este valor de k. Pueden verse las matrices de confusión de k en la Fig. 1.




Fig. 1. Matrices de confusión de k

Segmentación de la imagen completa

Se transforma la imagen a una lista de píxeles para clasificarlos. Reorganizamos las componentes a y b de la imagen y empleando el modelo de color ya definido predecimos las etiquetas de cada pixel de la imagen. Finalmente reconstruimos este vector de etiquetas al tamaño original de la imagen (filas x columnas)

(Opcional) Filtrado posterior

Aplicamos un filtro de mediana para eliminar principalmente ruido, pues este es ideal para eliminar píxeles mal clasificados, al elegir un valor alto como [9 9], se elimina bastante ruido, pero no se puede eliminar por completo, pues de usar valores aún mayores se perdería nitidez.




Fig. 2. Comparación de resultados con y sin filtro

- Segmentación basada en características de color y en posicionamiento (2.5p)

Obtenemos todas las mallas de coordenadas de nuestra imagen, tanto del fondo como de las pelotas para más adelante balancear y crear otro vector de etiquetas, pues estamos repitiendo el mismo proceso que antes.

Normalización

Se emplea la misma partición “cv” que utilizamos anteriormente para una mejor comparación. Con esto calculamos los parámetros de media y desviación sobre train. Se aplica la normalización sobre el entrenamiento y la validación y finalmente normalizamos también los datos de la imagen completa para su segmentación.

Repetición del proceso de diseño y evaluación

Volvemos a seleccionar un k, esta vez parece ser 1 el valor óptimo de este parámetro. Con esto creamos el modelo final y lo visualizamos. Los resultados son los esperados, pues al añadir los parámetros “x” e “y”, el ruido prácticamente desaparece, pero este método tiene la contraparte de que algunas figuras pueden sufrir anomalías si los parches no están bien seleccionados. Esto pasa en nuestro caso, pues no hemos definido patch para la parte del fondo abajo a la derecha, donde más se notan las anomalías.




Fig. 3. Comparación de resultados de ambos métodos

Objetivo creativo (2 puntos)

Clasificador Inteligente de Material Deportivo

Buscamos diseñar e implementar un algoritmo de inspección visual, que logre segmentar, identificar y etiquetar automáticamente cada tipo de balón (fútbol, rugby, tenis o baloncesto) que se encuentre en la imagen.

En él, además de aislar objetos, nuestro objetivo es realizar un análisis de forma y tamaño mediante la extracción de descriptores morfológicos, para la toma de decisiones de clasificación en los diferentes tipos de balones que encontremos, simulando un sistema de control de calidad.

Guía para la creación de nuestro algoritmo:

- **Paso 1: Pre-procesamiento de la imagen**

Aplicamos un desenfoque suave con un Filtro Gaussiano para operar con “manchas de color” lisas y que matlab no se confunda con detalles como las costuras, o las texturas de los balones.

- **Paso 2: Separación por color (Segmentación HSV)**

Pasamos la imagen al espacio HSV y creamos una máscara que detecte colores vivos y que ignore el fondo de la imagen.

- **Paso 3: Rellenar y separar (Morfología y Watershed)**

Rellenar los balones y separarlos para que MATLAB cuente con la cantidad de objetos indicados

- **Paso 4: Medir cada balón**

Usando regionprops medimos el área y el perímetro de cada balón. Con ello también calculamos como de redondo es cada uno para clasificarlo más adelante.

- **Paso 5: Clasificación**

Mediante un bucle clasificamos los balones según su morfología; Área pequeña -> Tenis, Área grande -> Baloncesto, Circularidad baja -> Fútbol, Circularidad alta -> Rugby.

- **Paso 6: Mostrar el resultado**

Dibujar un cuadro sobre la imagen original y escribir el nombre del balón encima usando los datos de posición (Centroid).




Fig. 4. Resultado visual del objetivo creativo

```
Balones detectados: 4
Objeto 1 -> Area: 73001 | Circularidad: 0.630
Objeto 2 -> Area: 61984 | Circularidad: 0.792
Objeto 3 -> Area: 130051 | Circularidad: 0.689
Objeto 4 -> Area: 35936 | Circularidad: 0.966
```

Fig. 5. Datos obtenidos del objetivo creativo